

PERBANDINGAN ALGORITMA MACHINE LEARNING: SVM, RANDOM FOREST, DAN XGBOOST UNTUK PREDIKSI STROKE

¹⁾ Hanifah Afkar Nabila, ²⁾ Endang Wahyu Pamungkas

^{1,2)} Teknik Informatika, Ilmu Komunikasi dan Informatika, Universitas Muhammadiyah Surakarta

^{1,2)} Jl. Ahmad Yani, Tromol Pos 1, Pabelan, Kartasura, Surakarta – Jawa Tengah - Indonesia

E-mail : ¹⁾ 1200214252@student.ums.ac.id, ²⁾ ewp123@ums.ac.id

ABSTRAK

Stroke merupakan salah satu penyebab utama kematian dan kecacatan di dunia sehingga deteksi dini sangat penting. Penelitian ini membandingkan tiga algoritma machine learning yaitu Support Vector Machine (SVM), Random Forest dan XGBoost untuk prediksi risiko stroke. Dataset yang digunakan mencakup data publik dari Kaggle untuk pelatihan dan data klinis sebanyak 2.533 pasien dari Puskesmas Baturetno 2 sebagai validasi eksternal. Pra-pemrosesan meliputi penanganan nilai hilang, encoding fitur kategorikal, normalisasi, dan penyeimbangan data menggunakan SMOTE. Evaluasi dilakukan dengan metrik akurasi, presisi, recall, F1-score, AUC-ROC dan AUC-PRC. Hasil menunjukkan bahwa Random Forest memberikan performa terbaik dengan akurasi 98,61 persen dan AUC-ROC 98,96 persen pada data klinis diikuti oleh XGBoost yang juga menunjukkan performa kuat. Penelitian ini tidak hanya menegaskan pentingnya validasi eksternal tetapi juga menyoroti nilai penggunaan data lokal dalam membangun sistem prediksi medis yang andal dan relevan secara kontekstual.

Kata Kunci: Machine learning, Random Forest, stroke, Support Vector Machine (SVM), XGBoost.

ABSTRACT

Stroke is one of the leading causes of death and disability in the world so early detection is very important. This study compares three machine learning algorithms namely Support Vector Machine (SVM), Random Forest and XGBoost for stroke risk prediction. The dataset used includes public data from Kaggle for training and clinical data of 2.533 patients from Puskesmas Baturetno 2 as external validation. Pre-processing includes missing value handling, categorical feature encoding, normalization, and data balancing using SMOTE. We evaluated model performance using accuracy, precision, recall, F1-score, AUC-ROC, and AUC-PRC metrics. Results showed that Random Forest gave the best performance with 98.61 percent accuracy and 98.96 percent AUC-ROC on clinical data followed by XGBoost which also showed strong performance. This research not only confirms the importance of external validation but also highlights the value of using local data in building reliable and contextually relevant medical prediction systems.

Keyword: Machine learning, Random Forest, stroke, Support Vector Machine (SVM), XGBoost.

PENDAHULUAN

Stroke merupakan gangguan aliran darah ke otak akibat penyumbatan (stroke iskemik) atau pecahnya pembuluh darah (stroke hemoragik), yang dapat menyebabkan kerusakan jaringan otak, kecacatan permanen, hingga kematian [1]. Menurut *Clinical Guideline of Acute Stroke* (2012), terdapat sekitar 15 juta kasus stroke setiap tahun di dunia, dengan lima juta kematian dan sepuluh juta kasus kecacatan permanen. Stroke menjadi penyebab kematian ketiga setelah penyakit jantung dan kanker. Di Asia, Indonesia termasuk negara dengan angka kejadian tinggi, sekitar 500 ribu kasus per tahun [2].

Deteksi dini berperan penting dalam pencegahan dan penanganan stroke. Pendekatan prediksi berbasis kecerdasan buatan (*Artificial Intelligence/AI*), khususnya machine learning (ML), menawarkan potensi akurasi yang tinggi dalam mengidentifikasi risiko stroke. Penelitian ini membandingkan tiga algoritma ML yaitu Support Vector Machine (SVM), Random Forest, dan XGBoost, yang memiliki karakteristik berbeda. SVM cocok untuk data berdimensi tinggi dan linear, Random Forest unggul pada data kompleks dengan pendekatan ensemble, sedangkan XGBoost efektif dalam menangani data tidak seimbang melalui teknik boosting dan regularisasi.

Penelitian yang dilakukan oleh Aulia et al. [3] membandingkan Decision Tree, Naïve Bayes, dan Random Forest, dengan hasil terbaik pada Decision Tree (akurasi 95,13%). Studi lain oleh Nurqotimah et al. [4] menggunakan SVM dengan kernel RBF pada 40.910 data pasien dan mencapai akurasi 94,8%. Sementara itu, penelitian oleh Hutabarat et al. [5] menemukan bahwa XGBoost menunjukkan performa terbaik (precision 0,90, recall 0,95, f1-score 0,92, ROC-AUC 0,978).


Namun, sebagian besar penelitian masih bergantung pada dataset publik seperti Kaggle, yang kurang merepresentasikan populasi lokal Indonesia. Padahal, studi menunjukkan bahwa pencatatan medis manual di fasilitas kesehatan seperti puskesmas menghambat deteksi cepat [6]. Beberapa studi menggunakan algoritma seperti K-Nearest Neighbor (K-NN), namun fokusnya lebih pada sistem, bukan evaluasi performa model secara komparatif.

Keterbatasan dalam penelitian terdahulu mencakup kurangnya teknik penyeimbangan data [3], minimnya perbandingan lintas algoritma [4], serta kurangnya penekanan pada validasi dan isu ketidakseimbangan kelas [5]. Selain itu, validasi eksternal menggunakan data klinis nyata belum banyak dilakukan, padahal data seperti dari Puskesmas lebih mencerminkan kondisi lapangan dibandingkan data Kaggle. Penelitian ini mengisi celah tersebut dengan mengevaluasi SVM, Random Forest, dan XGBoost menggunakan kombinasi teknik preprocessing, penyeimbangan data, serta validasi eksternal menggunakan data klinis dari Puskesmas Baturetno II. Pemilihan dataset Kaggle sebagai data pelatihan didasarkan pada ketersediaan fitur klinis yang lengkap dan struktur data yang telah terstandarisasi, sehingga sangat sesuai untuk proses pelatihan awal model prediksi stroke. Untuk memastikan bahwa model yang dibangun tidak hanya efektif

pada data pelatihan tetapi juga mampu bekerja secara andal dalam konteks lokal, penelitian ini secara sengaja menggunakan data eksternal dari Puskesmas sebagai data uji. Pendekatan ini dirancang untuk menguji kemampuan generalisasi model terhadap populasi dengan karakteristik demografis dan klinis yang berbeda, khususnya populasi Indonesia. Dengan membandingkan karakteristik kedua dataset, penelitian ini tidak hanya menilai akurasi model, tetapi juga mengevaluasi robustitas dan aplikabilitasnya dalam skenario dunia nyata.

METODE

Penelitian ini dimulai dengan pengumpulan data dari sumber terbuka, dilanjutkan dengan persiapan data melalui penanganan nilai hilang, encoding variabel kategorikal dan normalisasi, yang merupakan tahap penting dalam meningkatkan kualitas data dan performa model [7]. Setelah itu, dilakukan penyeimbangan data agar distribusi kasus stroke dan non-stroke menjadi seimbang. Data yang telah siap digunakan untuk pelatihan dan evaluasi model dengan tiga algoritma machine learning, yaitu SVM, Random Forest dan XGBoost. Seluruh proses ini dapat dilihat secara ringkas pada Gambar 1, yang menampilkan diagram alur penelitian dari tahap pengumpulan data hingga validasi eksternal menggunakan data dari praktik klinis. Validasi eksternal ini bertujuan untuk menguji performa model dalam konteks dunia nyata.



Gambar 1. Diagram Alur

Pengumpulan Data

Data yang digunakan dalam penelitian ini berasal dari dua sumber, yaitu dataset publik Kaggle yang terdiri dari 5.110 data pasien [8] dan data klinis dari Puskesmas Baturetno II Wonogiri sebanyak 2.533 pasien [9]. Data Puskesmas diseleksi berdasarkan kriteria inklusi yaitu pasien dewasa dengan data lengkap pada atribut gender, age, hypertension, heart_disease, work_type, avg_glucose_level, bmi dan stroke. Data duplikat dan tidak lengkap dikeluarkan. Beberapa fitur yang tidak tersedia di data Puskesmas dihapus sejak awal proses pelatihan untuk memastikan kesesuaian struktur fitur antara data pelatihan dan pengujian.

Pada tahap selanjutnya, model yang telah dilatih akan dievaluasi kembali menggunakan data dari Puskesmas sebagai bentuk validasi dalam konteks dunia nyata. Mengingat adanya keterbatasan dalam akses dan ketersediaan informasi pada data Puskesmas, beberapa fitur yang tidak tersedia di dalamnya dihapus sejak awal proses pelatihan. Hal ini dilakukan untuk memastikan kesesuaian struktur fitur antara data pelatihan dan data pengujian, sehingga hasil evaluasi model tetap valid dan konsisten.

Penggunaan data klinis ini telah memperoleh persetujuan dari pihak Puskesmas dan seluruh data telah dianonimkan sebelum digunakan. Penelitian ini tidak melibatkan intervensi langsung terhadap pasien dan telah mematuhi prinsip etika penelitian yang berlaku.

Data Preparation


1. Penyesuaian Atribut

Dalam tahap penyesuaian fitur, beberapa atribut dihapus dari dataset Kaggle karena tidak tersedia dalam data klinis dari Puskesmas yang digunakan sebagai data validasi eksternal. Atribut yang dihapus meliputi ever_married, residence_type, dan


smoking_status. Penghapusan ini bertujuan untuk menjaga konsistensi struktur fitur antara data pelatihan dan data pengujian, sehingga proses validasi model dapat berjalan secara optimal dan hasil evaluasi menjadi lebih akurat.

Secara klinis, ever_married dan residence_type dinilai memiliki kontribusi yang rendah terhadap risiko stroke, sehingga penghapusannya tidak diharapkan berdampak signifikan terhadap performa prediktif model. Sementara itu, meskipun smoking_status merupakan faktor risiko yang relevan, fitur ini tetap dihapus karena tidak tersedia dalam data validasi eksternal. Selain itu, analisis korelasi menunjukkan bahwa hubungan antara smoking_status dan stroke relatif lemah ($r \approx 0.05$), sehingga fitur tersebut dikeluarkan dari proses pelatihan untuk menjaga kompatibilitas model dengan data dunia nyata sekaligus menghindari inkonsistensi fitur saat validasi.

Data dari Puskesmas diseleksi berdasarkan kriteria inklusi, yaitu pasien dewasa dengan data lengkap pada delapan fitur utama yang digunakan dalam pelatihan model: gender, age, hypertension, heart_disease, work_type, avg_glucose_level, bmi, dan stroke. Data yang tidak memenuhi kelengkapan atau mengandung nilai ekstrem yang tidak wajar dikeluarkan melalui proses eksklusi. Untuk menunjukkan transparansi proses preprocessing, distribusi kelas stroke sebelum dan sesudah penyeimbangan data ditampilkan pada Gambar 2 dan Gambar 3. Gambar 2 memperlihatkan ketimpangan distribusi antara kelas stroke dan non-stroke, sedangkan Gambar 3 menunjukkan distribusi kelas setelah penerapan teknik SMOTE. Visualisasi ini memperjelas bahwa SMOTE berhasil menyeimbangkan jumlah sampel pada kedua kelas, sehingga model dapat belajar secara lebih adil dalam mendeteksi kasus stroke yang jumlahnya jauh lebih sedikit dalam data mentah.



Gambar 2. Distribusi kelas pada dataset sebelum penerapan SMOTE



Gambar 3. Distribusi kelas pada dataset setelah penerapan SMOTE

2. Penanganan Missing Value

Pemeriksaan awal dilakukan untuk memastikan tidak terdapat nilai kosong (missing values) dalam dataset. Apabila ditemukan, penanganan dilakukan dengan teknik imputasi yang sesuai dengan jenis datanya. Untuk fitur numerik seperti BMI, nilai kosong diisi menggunakan nilai median, mengingat median lebih tahan terhadap outlier dan mampu mempertahankan karakteristik distribusi data. Sementara itu, untuk fitur kategorikal, imputasi dilakukan dengan menggunakan modus, yaitu nilai yang paling sering muncul dalam kolom tersebut. Strategi ini selaras dengan praktik umum dalam tahap pra-pemrosesan data, di mana penggunaan median untuk data numerik dan

modus untuk data kategorikal telah terbukti efektif dalam menjaga konsistensi dan integritas dataset [10], [11].

3. Encoding Fitur Kategorikal

Fitur kategorikal seperti jenis kelamin dan jenis pekerjaan dikonversi ke dalam format numerik menggunakan metode one-hot encoding dengan bantuan fungsi `pandas.get_dummies()`. Teknik ini menghasilkan representasi biner untuk setiap kategori, di mana setiap nilai unik diubah menjadi kolom terpisah dengan nilai satu untuk kehadiran dan nol untuk ketidakhadiran. Pendekatan ini efektif untuk menghindari asumsi hubungan ordinal antar kategori. Namun demikian, one-hot encoding dapat secara signifikan meningkatkan dimensi dataset apabila jumlah kategori cukup banyak, sehingga perlu dipertimbangkan dengan cermat berdasarkan ukuran dan kompleksitas data yang digunakan [12].

4. Normalisasi (*Scaling*)

Dalam proses pengolahan data untuk keperluan model pembelajaran mesin, normalisasi merupakan langkah penting guna memastikan bahwa seluruh fitur numerik berada pada skala yang sebanding, sehingga tidak ada satu fitur pun yang mendominasi proses pelatihan. Salah satu metode normalisasi yang sering diterapkan adalah standarisasi, yang dapat dilakukan menggunakan fungsi `StandardScaler`. Metode ini mentransformasi data agar memiliki distribusi dengan rata-rata nol dan standar deviasi satu, sehingga mampu meningkatkan kestabilan pelatihan model dan mencegah bias yang disebabkan oleh perbedaan skala antar fitur [13].

5. Pembagian dan Penyeimbangan Data

Distribusi kelas pada dataset Kaggle menunjukkan ketidakseimbangan, di mana jumlah kasus stroke jauh lebih sedikit

dibandingkan dengan kasus non-stroke. Ketidakseimbangan ini dapat menyebabkan model cenderung memihak kelas mayoritas dan mengabaikan kasus stroke yang sebenarnya penting untuk dikenali. Untuk mengatasi hal tersebut, dilakukan pembagian dataset menjadi data latih dan data uji dengan proporsi 80:20 secara stratifikasi berdasarkan label kelas, guna menjaga distribusi kelas pada masing-masing subset.

Pembagian data dilakukan dengan menetapkan `random_state = 42` untuk menjamin replikabilitas. Selanjutnya, diterapkan metode Synthetic Minority Over-sampling Technique (SMOTE) pada data latih. SMOTE bekerja dengan membangkitkan sampel sintetis pada kelas minoritas melalui interpolasi antar data yang berdekatan dalam ruang fitur.

Proses ini menghasilkan dataset pelatihan yang lebih seimbang, sehingga model dapat belajar secara adil terhadap kedua kelas. Teknik ini dipilih karena telah terbukti efektif dalam berbagai studi terdahulu dan lebih unggul dibandingkan metode undersampling, terutama dalam meningkatkan performa model pada klasifikasi medis [14] [15].

Modelling

1. Support Vector Machine (SVM)

Support Vector Machine (SVM) merupakan salah satu algoritma klasifikasi yang dikenal efektif dalam mengelola data dengan dimensi tinggi dan kompleksitas yang tinggi, menjadikannya sangat relevan untuk digunakan dalam konteks prediksi di bidang kesehatan. Algoritma ini beroperasi dengan cara mencari hyperplane optimal yang dapat memisahkan dua kelas data dengan margin maksimum, di mana titik-titik data yang paling dekat dengan hyperplane tersebut disebut sebagai support vectors [16].

2. Random Forest

Random Forest merupakan algoritma ensemble learning yang dibangun berdasarkan struktur pohon keputusan (decision tree). Metode ini menghasilkan sejumlah pohon keputusan secara acak, kemudian menentukan hasil prediksi akhir berdasarkan mekanisme voting dalam kasus klasifikasi. Salah satu keunggulan utama dari Random Forest adalah kemampuannya dalam mengolah data dengan fitur numerik maupun kategorikal secara efektif. Selain itu, pendekatan bagging (bootstrap aggregating) yang diterapkan pada algoritma ini turut meningkatkan ketahanannya terhadap permasalahan overfitting, sehingga membuatnya andal dalam menangani data yang kompleks.

3. Extreme Gradient Boosting (XGBoost)

XGBoost merupakan algoritma boosting yang dirancang untuk efisiensi dan akurasi tinggi dalam pembelajaran mesin. Algoritma ini membangun model secara bertahap untuk memperbaiki kesalahan prediksi sebelumnya, serta dilengkapi dengan teknik regularisasi guna mengurangi risiko overfitting. XGBoost terbukti efektif untuk data kompleks dan tidak seimbang, termasuk pada klasifikasi data medis seperti prediksi stroke [17]. Kombinasi XGBoost dengan teknik penyeimbangan data seperti SMOTE telah menunjukkan peningkatan performa klasifikasi yang signifikan pada dataset dengan distribusi kelas tidak proporsional [18].

Algoritma lain seperti Naive Bayes tidak digunakan karena mengasumsikan independensi antar fitur, yang tidak sesuai untuk data medis di mana banyak variabel saling berkorelasi, seperti hipertensi, glukosa, dan BMI. Neural Network juga tidak diterapkan karena keterbatasan jumlah data dan rendahnya interpretabilitas, yang penting dalam konteks klinis untuk menjelaskan hasil prediksi kepada

tenaga medis. Seluruh model dijalankan menggunakan default hyperparameter dari pustaka scikit-learn dan XGBoost untuk menjaga keadilan komparasi serta menghindari overfitting, mengingat jumlah data terbatas. Pendekatan ini telah digunakan secara luas dan terbukti cukup representatif dalam berbagai studi pembelajaran mesin.

Evaluation

Evaluasi performa model dalam penelitian ini dilakukan dengan menggunakan metrik klasifikasi yang meliputi akurasi, precision, recall (sensitivitas), F1-score, serta AUC-ROC dan AUC-PRC. Metrik ini digunakan untuk mengukur seberapa baik model dalam mengidentifikasi kasus stroke, baik secara keseluruhan maupun khusus pada kasus yang jarang (kelas minoritas).

Pemilihan metrik ini tidak hanya menggambarkan performa numerik, tetapi juga merefleksikan implikasi klinis dalam deteksi stroke. Mengoptimalkan model berdasarkan precision, recall, dan F1-score sangat krusial, karena kesalahan klasifikasi pada kasus stroke bisa berdampak serius [19]. Studi sebelumnya juga menunjukkan bahwa pemanfaatan model klasifikasi dengan mempertimbangkan precision dan recall dapat meningkatkan akurasi klinis dalam pengambilan keputusan [20].

Selain itu, AUC-PRC (Area Under the Precision-Recall Curve) juga menjadi indikator penting dalam mengevaluasi performa model klasifikasi pada kondisi data tidak seimbang, seperti prediksi stroke, di mana jumlah kasus positif jauh lebih sedikit dibandingkan kasus negatif. Metrik ini mampu memberikan gambaran yang lebih representatif terhadap kemampuan model dalam mendeteksi kelas minoritas secara akurat [21].

Untuk mengevaluasi efisiensi klinis dari setiap model, digunakan pula metrik *Number*

Needed to Diagnose (NND), yang menunjukkan rata-rata jumlah pemeriksaan yang diperlukan untuk menghasilkan satu diagnosis positif yang benar. Semakin kecil nilai NND, semakin efisien model dalam praktik klinis. Metrik ini dihitung berdasarkan *sensitivity* (atau recall) dan *specificity*, sehingga mencerminkan kemampuan model dalam mendeteksi kasus positif dan negatif secara benar [22]. Secara matematis, NND dapat dihitung menggunakan rumus sebagai berikut:

$$NND = \frac{1}{Sensitivity + Specificity - 1}$$

Dengan:

- $Sensitivity = TP / (TP + FN)$
- $Specificity = TN / (TN + FP)$

Rumus ini merujuk pada *Youden's Index*, yang menggabungkan performa model dalam mendeteksi kasus positif dan negatif secara akurat. Dalam penelitian ini, NND dihitung berdasarkan hasil prediksi pada data uji eksternal untuk mencerminkan efisiensi model dalam konteks aplikasi nyata.

Terakhir, untuk melengkapi evaluasi performa model, digunakan uji McNemar sebagai uji statistik non-parametrik untuk membandingkan dua model klasifikasi biner pada dataset yang sama. Uji ini menghasilkan nilai p-value untuk menentukan apakah perbedaan performa kedua model signifikan secara statistik atau hanya terjadi karena faktor kebetulan [23].

External Validation Using Clinical Data

Setelah model dilatih dan dievaluasi menggunakan data dari Kaggle, langkah selanjutnya adalah melakukan validasi eksternal menggunakan data dari Puskesmas. Validasi ini bertujuan untuk menilai kemampuan generalisasi model terhadap data

yang berasal dari distribusi berbeda dengan data pelatihan. Model dengan performa terbaik pada tahap sebelumnya kemudian diuji menggunakan data Puskesmas yang telah disesuaikan dengan struktur fitur pada dataset Kaggle. Proses ini dilakukan untuk mengukur efektivitas model dalam konteks praktik medis nyata, serta memastikan bahwa model mampu memberikan prediksi yang andal ketika diterapkan di lapangan.

Berbeda dari studi sebelumnya yang hanya mengandalkan dataset publik, pendekatan validasi eksternal berbasis data klinis menjadikan penelitian ini lebih aplikatif dan mendekati penerapan nyata di sektor layanan kesehatan dasar.

HASIL

1. Data Collection

Penelitian ini menggunakan dua sumber data utama. Sumber pertama berasal dari dataset publik Kaggle yang terdiri dari 5.110 data rekam medis dan informasi pasien, yang digunakan untuk membangun model klasifikasi menggunakan algoritma Machine Learning seperti Support Vector Machine (SVM), Random Forest, dan XGBoost. Sumber data kedua diperoleh dari Puskesmas Baturetno II Wonogiri, yang digunakan sebagai data validasi eksternal. Dataset ini mencakup 2533 data pasien dan telah melalui proses pembersihan, termasuk penghapusan duplikasi dan penanganan missing value, sehingga siap digunakan untuk menguji kemampuan generalisasi model dalam konteks dunia nyata.

2. Data Preparation

Pada tahap awal, dilakukan proses preparasi data dengan menyelaraskan atribut antara dataset Kaggle dan data dari Puskesmas, yaitu gender, age, hypertension, heart_disease, work_type, avg_glucose_level, bmi dan stroke, guna menjaga konsistensi struktur data. Nilai

kosong pada kolom bmi diimputasi menggunakan rata-rata agar kelengkapan dan distribusi data tetap terjaga. Selanjutnya, variabel kategorikal dikodekan menggunakan metode One-Hot Encoding melalui fungsi `pd.get_dummies()`, untuk mengubah nilai kategori menjadi representasi biner tanpa mengasumsikan adanya hubungan ordinal antar kategori [24]. Sementara itu, fitur numerik dinormalisasi menggunakan `StandardScaler` agar berada pada skala yang seragam, yang sangat penting untuk meningkatkan performa algoritma klasifikasi yang sensitif terhadap skala data, seperti Support Vector Machine (SVM).

3. Pembagian dan Penyeimbangan Data

Ketidakseimbangan kelas antara stroke dan non-stroke terbukti mempengaruhi performa model, khususnya dalam mendeteksi kasus stroke. Tanpa penyeimbangan, model cenderung bias terhadap kelas mayoritas sehingga recall pada kelas stroke menjadi rendah.

Setelah penerapan SMOTE pada data latih, terjadi peningkatan signifikan pada metrik recall dan F1-score, khususnya pada algoritma Random Forest dan XGBoost. Hasil ini sejalan dengan penelitian sebelumnya yang menunjukkan bahwa SMOTE dapat meningkatkan performa model pada data dengan distribusi kelas tidak seimbang [25], Penerapan SMOTE juga terbukti efektif dalam meningkatkan sensitivitas model pada tugas klasifikasi berbasis machine learning, termasuk pada studi yang menggunakan algoritma Random Forest dan SVM [26], [27].

Dengan pendekatan ini, model dalam penelitian ini mampu mengenali pola kasus stroke dengan lebih baik tanpa menurunkan akurasi keseluruhan. Berikut ditampilkan pseudocode yang merepresentasikan proses pembagian fitur dan target serta penerapan

SMOTE untuk penyeimbangan data latih

```
# Split features and target
X_kaggle = kaggle_df.drop("stroke",
axis=1)
y_kaggle = kaggle_df["stroke"]
X_puskesmas =
puskesmas_df.drop("stroke", axis=1)
y_puskesmas = puskesmas_df["stroke"]
```

```
# Balance kaggle dataset
smote = SMOTE(random_state=42)
X_bal, y_bal =
smote.fit_resample(X_kaggle,
y_kaggle)
```

Modeling dan Evaluasi

Evaluasi kinerja model dilakukan dengan menggunakan metrik akurasi, precision, recall, dan F1-score untuk mengukur sejauh mana model mampu melakukan prediksi kasus stroke secara tepat dan seimbang. Selain itu, digunakan pula metrik AUC-ROC (*Area Under the Receiver Operating Characteristic Curve*) sebagai pelengkap evaluasi. AUC-ROC dinilai penting, terutama pada data dengan distribusi kelas yang tidak seimbang, karena mampu mengevaluasi kemampuan model dalam membedakan antara kelas stroke dan non-stroke secara menyeluruh tanpa bergantung pada satu nilai ambang klasifikasi tertentu. Dalam konteks medis, penggunaan metrik ini menjadi krusial karena kesalahan prediksi (*false negative*) dapat menyebabkan keterlambatan diagnosis dan berisiko memperburuk kondisi klinis pasien.

Selain evaluasi performa klasifikasi, pengukuran waktu komputasi juga dilakukan untuk menilai efisiensi masing-masing model. Hasilnya menunjukkan bahwa XGBoost memiliki waktu pelatihan tercepat, yaitu sekitar 0.14 detik, diikuti oleh Random Forest dengan waktu komputasi 2.60 detik, dan SVM yang memerlukan waktu paling lama, yaitu 8.04 detik. Meskipun Random Forest dan XGBoost

menunjukkan akurasi yang lebih tinggi, perbedaan waktu pelatihan ini menjadi pertimbangan penting dalam pemilihan model, terutama dalam konteks implementasi di lingkungan klinis yang memerlukan proses prediksi cepat atau memiliki keterbatasan sumber daya komputasi.

1. SVM

Model SVM menunjukkan performa yang cukup baik pada data pelatihan Kaggle. Model ini memperoleh akurasi sebesar 84.37%, precision 82.08%, recall 87.83%, dan F1-score 84.86%. Nilai AUC-ROC rata-rata dari lima fold cross-validation sebesar 0.92, sedangkan AUC-PRC mencapai 0.92, menandakan keseimbangan yang cukup baik antara sensitivitas dan presisi. Waktu komputasi SVM tercatat paling tinggi di antara seluruh model, yaitu 8.0351 detik, menjadikannya kurang efisien untuk sistem dengan kebutuhan respon cepat. Berdasarkan confusion matrix, model SVM menghasilkan 852 true positive, 789 true negative, dengan 186 false positive dan 118 false negative, yang berdampak pada potensi kesalahan diagnosis kasus stroke.

2. Random Forest

Random Forest menunjukkan performa yang sangat baik secara keseluruhan. Model ini mencatatkan akurasi sebesar 93.93%, precision 92.52%, recall 95.57%, dan F1-score 94.02%. Nilai AUC-ROC dan PRC-AUC yang tinggi (keduanya sekitar 0.98) menunjukkan konsistensi model dalam mengenali kelas stroke secara akurat. Dalam hal efisiensi, Random Forest memiliki waktu komputasi yang cukup cepat, yaitu 2.6012 detik. Hasil prediksi menunjukkan 927 true positive dan 900 true negative, serta hanya menghasilkan 75 false positive dan 43 false negative, mencerminkan kestabilan tinggi dalam klasifikasi dua kelas dan kesalahan prediksi

yang relatif rendah.

3. Xgboost


XGBoost merupakan salah satu model dengan kinerja paling konsisten pada dataset pelatihan. Model ini memperoleh akurasi sebesar 94.04%, precision 93.04%, recall 95.15%, dan F1-score 94.09%. Selain itu, nilai AUC-ROC sebesar 0.99 dan PRC-AUC sebesar 0.99 menunjukkan kestabilan tinggi dalam mengenali kasus stroke, bahkan pada kondisi distribusi kelas yang tidak seimbang. Dari sisi efisiensi komputasi, XGBoost menunjukkan waktu prediksi yang paling singkat, yaitu hanya 0.1388 detik, yang dapat menjadi pertimbangan penting untuk implementasi sistem prediksi berskala besar. Berdasarkan hasil klasifikasi, model menghasilkan 923 true positive, 906 true negative, dengan 69 false positive dan 47 false negative, sehingga mampu menjaga keseimbangan antara sensitivitas dan spesifisitas dengan baik.

Table 1. Rata-rata evaluasi metrik model kaggle

Metriks	SVM	Random Forest	XGBoost
Accuracy (%)	84.37	93.93	94.04
Precision (%)	82.08	92.52	93.04
Recall (%)	87.84	95.57	95.15
F1-score (%)	84.86	94.02	94.09
ROC-AUC (%)	92.07	98.69	98.84
PRC-AUC (%)	91.59	98.74	98.91

Model Random Forest dan XGBoost menunjukkan performa yang lebih kuat dibandingkan Support Vector Machine (SVM)

pada dataset Kaggle. Kedua model tersebut mencatatkan nilai akurasi di atas 93%, F1-score di atas 94%, serta nilai AUC-ROC dan AUC-PRC mendekati 0.99, yang mencerminkan konsistensi tinggi dalam mendeteksi kasus stroke maupun non-stroke. Sebaliknya, SVM menunjukkan performa yang lebih rendah, dengan akurasi 84.37% dan F1-score 84.86%, serta AUC-PRC yang lebih rendah dibandingkan dua model lainnya. Hal ini menunjukkan keterbatasan SVM dalam mengenali kelas positif secara optimal, terutama pada kondisi distribusi data yang tidak seimbang. Gambar 5 yang memvisualisasikan metrik evaluasi tiap model, mendukung temuan ini dengan menunjukkan adanya perbedaan performa yang jelas, terutama pada metrik recall dan PRC-AUC. Temuan ini menunjukkan bahwa Random Forest dan XGBoost lebih stabil dan adaptif terhadap karakteristik data pelatihan, sehingga memiliki potensi yang lebih baik untuk diterapkan dalam sistem prediksi di dunia nyata.



Gambar 4. Grafik perbandingan metrik evaluasi data kaggle

Validasi Eksternal dengan Data Puskesmas

1. SVM

Model Support Vector Machine (SVM) mengalami penurunan performa yang cukup signifikan ketika diuji pada data eksternal dari klinik. Akurasi model tercatat sebesar 75.40%, dengan precision 50.88% dan recall 50.32%, menghasilkan F1-score sebesar 50.59%. Nilai

AUC-ROC sebesar 76.74% dan AUC-PRC sebesar 49.41% menunjukkan keterbatasan model dalam membedakan kasus stroke dan non-stroke secara akurat, khususnya dalam mendeteksi kelas minoritas. Selain itu, nilai *Number Needed to Diagnose* (NND) untuk SVM sebesar 2,93, mengindikasikan bahwa diperlukan hampir tiga pemeriksaan untuk mendapatkan satu diagnosis stroke yang benar. Hal ini mencerminkan efisiensi klinis yang rendah, dan menegaskan bahwa model SVM kurang adaptif terhadap distribusi data yang berbeda dari data pelatihan serta memiliki sensitivitas rendah terhadap kasus stroke.

2. Random Forest

Model Random Forest menunjukkan performa yang sangat baik dalam validasi eksternal. Akurasi yang dicapai sebesar 92.03%, dengan precision sebesar 94.63% dan recall sebesar 72.24% pada kelas stroke. F1-score sebesar 81.93% menunjukkan keseimbangan yang baik antara ketepatan dan sensitivitas. Nilai AUC-ROC mencapai 93.41% dan AUC-PRC sebesar 88.85%, menandakan bahwa model ini tetap konsisten dalam mengenali kelas minoritas, meskipun data berasal dari distribusi yang berbeda.

Lebih lanjut, nilai NND untuk Random Forest sebesar 1,41, yang merupakan nilai terendah di antara ketiga model. Artinya, hanya dibutuhkan sekitar satu hingga dua pemeriksaan untuk menghasilkan satu diagnosis positif yang benar. Efisiensi klinis ini menjadikan Random Forest sebagai model yang paling andal untuk digunakan dalam deteksi stroke di lingkungan dunia nyata. Validasi silang eksternal juga menunjukkan stabilitas performa dengan rata-rata ROC-AUC sebesar 92.21%, mendukung kemampuan generalisasi model.

3. Xgboost

Model XGBoost juga menunjukkan performa yang kuat saat divalidasi menggunakan data klinik. Akurasi tercatat sebesar 89.62%, dengan precision 90.24% dan recall 65.62%, menghasilkan F1-score sebesar 75.98%. Nilai AUC-ROC sebesar 88.68% dan AUC-PRC sebesar 82.35% menunjukkan kemampuan model dalam mengenali kasus stroke dengan cukup baik meskipun tidak seoptimal Random Forest.

Nilai NND yang dihasilkan sebesar 1,58, menunjukkan efisiensi yang relatif baik, hanya sedikit di atas Random Forest. Hal ini mengindikasikan bahwa XGBoost tetap dapat diandalkan secara klinis, meskipun performanya sedikit lebih rendah. Validasi silang pada data klinik juga menghasilkan rata-rata ROC-AUC sebesar 89.84%, yang mencerminkan stabilitas performa model terhadap variasi data.

Table 2. Rata-rata evaluasi metrik model puskesmas


Metriks	SVM	Random Forest	XGBoost
Accuracy (%)	75.40	92.03	89.62
Precision (%)	50.88	94.63	90.24
Recall (%)	50.32	72.24	65.62
F1-score (%)	50.59	81.93	75.98
ROC-AUC (%)	76.74	93.41	88.68
PRC-AUC (%)	49.41	88.85	82.35
NND	2.93	1.41	1.58

Berdasarkan Tabel 2, Random Forest dan XGBoost menunjukkan performa yang tinggi dan stabil saat diuji dengan data klinik, dengan akurasi, F1-score, dan AUC yang mencerminkan kemampuan generalisasi yang baik. Sebaliknya, SVM mengalami penurunan performa yang signifikan, terutama pada

precision dan recall.

Dari sisi efisiensi klinis, metrik *Number Needed to Diagnose* (NND) menunjukkan bahwa Random Forest (1,41) dan XGBoost (1,58) lebih efisien dibandingkan SVM (2,93). Nilai NND yang rendah mengindikasikan bahwa lebih sedikit pemeriksaan diperlukan untuk mendeteksi satu kasus stroke secara benar.

Visualisasi pada Gambar 6 turut memperjelas perbedaan performa antar model. Secara keseluruhan, Random Forest dan XGBoost dinilai lebih tangguh, adaptif, dan efisien untuk diterapkan dalam sistem pendukung keputusan medis.



Gambar 5. Grafik perbandingan metrik evaluasi data puskesmas

4. Analisis Performa Algoritma

Performa algoritma Support Vector Machine (SVM) secara konsisten lebih rendah dibandingkan Random Forest dan XGBoost, terutama saat diuji pada data klinik. Hal ini berkaitan dengan karakteristik SVM yang bekerja optimal pada data yang seimbang dan bebas noise—kondisi yang jarang ditemukan dalam data medis dunia nyata.

Meskipun telah dilakukan penyeimbangan kelas dengan SMOTE, performa SVM tetap menurun, terutama pada metrik recall dan precision. Ini menunjukkan keterbatasan SVM dalam mengenali pola pada kelas minoritas (stroke), serta sensitivitasnya terhadap distribusi data yang berbeda antara

pelatihan dan pengujian. Berbeda dengan Random Forest dan XGBoost yang dapat memprioritaskan fitur penting secara internal, SVM memperlakukan semua fitur secara setara, yang berpotensi menurunkan kinerja saat fitur bersifat ambigu.


Random Forest dan XGBoost menunjukkan performa lebih stabil dan akurat. Random Forest memperoleh recall sebesar 72,24% dengan AUC-ROC 0,93, sementara XGBoost mencapai recall 65,6% dengan AUC-ROC 0,89. Kedua model terbukti lebih tangguh terhadap variasi data dan noise berkat pendekatan ensemble yang adaptif.

Dari sisi klinis, recall tinggi menjadi indikator penting karena berhubungan langsung dengan deteksi kasus stroke secara tepat. Model yang gagal mendeteksi kasus stroke (false negative) dapat membahayakan keselamatan pasien akibat keterlambatan penanganan. Oleh karena itu, pemilihan model tidak hanya mempertimbangkan akurasi, tetapi juga dampaknya terhadap keselamatan pasien.

Sebagai pelengkap evaluasi, digunakan metrik *Number Needed to Diagnose* (NND) untuk menilai efisiensi klinis. Hasil perhitungan menunjukkan bahwa Random Forest memiliki NND paling rendah, yaitu (1,41), diikuti XGBoost (1,58), dan SVM (2,93). Artinya, Random Forest hanya memerlukan sekitar satu hingga dua pemeriksaan untuk menghasilkan satu diagnosis positif yang benar, menandakan efisiensi tinggi dalam praktik medis.

Melihat bahwa Random Forest dan XGBoost merupakan dua model dengan performa terbaik baik secara prediktif maupun klinis, dilakukan analisis lebih lanjut untuk mengetahui apakah perbedaan di antara keduanya bersifat signifikan secara statistik. Uji McNemar berdasarkan hasil prediksi terhadap data uji klinik menghasilkan nilai chi-square sebesar 34,29 dengan p-value sebesar $4,76 \times$

10^{-9} . Karena $p < 0,05$, maka perbedaan performa kedua model dinyatakan signifikan secara statistik. Temuan ini semakin memperkuat pemilihan Random Forest sebagai model terbaik, tidak hanya dari sisi metrik prediktif dan efisiensi klinis, tetapi juga berdasarkan signifikansi statistik. Untuk memperjelas hasil uji signifikansi antara kedua model, digunakan uji McNemar yang divisualisasikan pada Gambar 7. Visualisasi ini menunjukkan jumlah instance yang diklasifikasikan berbeda oleh Random Forest dan XGBoost pada data uji klinik.



Gambar 7. Uji McNemar antara Random Forest dan XGBoost pada data uji klinik.

KESIMPULAN

Penelitian ini membandingkan tiga algoritma klasifikasi, yaitu Support Vector Machine (SVM), Random Forest (RF), dan XGBoost (XGB) dalam prediksi stroke berbasis data klinik. Random Forest menunjukkan performa terbaik dengan recall sebesar 72,24 persen, AUC-ROC 0,93, dan nilai NND terendah yaitu 1,41. Uji McNemar menghasilkan p-value kurang dari 0,05, yang menandakan perbedaan performa dengan XGBoost signifikan secara statistik. Dengan demikian, Random Forest dinilai unggul dalam

ketepatan, efisiensi klinis, dan stabilitas terhadap variasi data. Sebaliknya, SVM kurang optimal pada data tidak seimbang dan rentan terhadap perubahan distribusi.

Penelitian selanjutnya disarankan untuk mengoptimasi parameter model, menggunakan data medis tambahan seperti hasil laboratorium, serta melakukan uji langsung di lingkungan klinis seperti Puskesmas. Penggunaan data dari berbagai fasilitas layanan kesehatan juga penting untuk meningkatkan generalisasi. Selain itu, interpretasi model perlu diperjelas agar hasil prediksi dapat lebih mudah dipahami oleh tenaga medis.

DAFTAR PUSTAKA

- [1] N. Biswas, K. M. M. Uddin, S. T. Rikta, and S. K. Dey, "A comparative analysis of machine learning classifiers for stroke prediction: A predictive analytics approach," *Healthcare Analytics*, vol. 2, no. October, p. 100116, 2022, doi: 10.1016/j.health.2022.100116.
- [2] Andreas Rantepadang, *Penanganan pasien stroke: pengaruh music movement therapy terhadap kekuatan otot, tingkat ansietas, dan tingkat ansietas, dan Tingkat Depresi pada Pasien Stroke*. Bintang Semesta Media, 2022.
- [3] Y. Aulia, A. Andriyansyah, S. Suharjo, and S. W. Nensi, "Analisis Prediksi Stroke dengan Membandingkan Tiga Metode Klasifikasi Decision Tree, Naïve Bayes, dan Random Forest," *Jurnal Ilmu Komputer dan Informatika*, vol. 3, no. 2, pp. 89–98, 2024, doi: 10.54082/jiki.90.
- [4] D. R. Nurqotimah, A. N. Khudori, and R. S. Pradini, "Journal Of Applied Computer Science And Technology (JACOST) Implementasi Algoritma Support Vector Machine (SVM) Untuk Klasifikasi Penyakit Stroke," vol. 5, no. 2, pp. 179–185, 2024.
- [5] F. K. Hutabarat *et al.*, "Comparison of Classification Algorithm in Predicting Stroke Disease," *Jurnal Sistem Informasi dan Ilmu Komputer Prima(JUSIKOM PRIMA)*, vol. 6, no. 1, pp. 99–104, 2022, doi: 10.34012/jurnalsisteminformasidanilmukomputer.v6i1.2714.
- [6] I. R. R. U. Rahmat Ardila Dwi Yulianto, "Perancangan Klasifikasi Pasien Stroke Dengan Metode K-Nearest Neighbor," *Rabit: Jurnal Teknologi dan Sistem Informasi Univrab*, vol. 8, no. 2, pp. 262–268, Sep. 2023.
- [7] I. Chahid, A. K. Elmiad, and M. Badaoui, "Data Preprocessing For Machine Learning

- Applications in Healthcare: A Review,” *Proceedings - SITA 2023: 2023 14th International Conference on Intelligent Systems: Theories and Applications*, pp. 1–6, 2023, doi: 10.1109/SITA60746.2023.10373591.
- [8] F. Soriano, “Stroke Prediction Datasets,” <https://www.kaggle.com/datasets/fedesoriano/stroke-prediction-dataset>.
- [9] Kairos Abinaya Susanto *et al.*, “Implementasi Bahasa Python Dalam Menganalisis Pengaruh Rokok Terhadap Risiko Pasien Terkena Penyakit Stroke,” *Jurnal Publikasi Teknik Informatika*, vol. 2, no. 2, pp. 48–58, 2023, doi: 10.55606/jupti.v2i2.1722.
- [10] J. J. Tanimu, M. Hamada, M. Hassan, H. Kakudi, and J. O. Abiodun, “Cervical Cancer,” pp. 1–23, 2022.
- [11] A. E. Karrar, “The Effect of Using Data Pre-Processing by Imputations in Handling Missing Values,” *Indonesian Journal of Electrical Engineering and Informatics*, vol. 10, no. 2, pp. 375–384, 2022, doi: 10.52549/ijeei.v10i2.3730.
- [12] M. K. Dahouda and I. Joe, “A Deep-Learned Embedding Technique for Categorical Features Encoding,” *IEEE Access*, vol. 9, pp. 114381–114391, 2021, doi: 10.1109/ACCESS.2021.3104357.
- [13] N. S. J. Jacobsen, D. Kristanto, S. Welp, Y. C. Inceler, and S. Debener, “Preprocessing choices for P3 analyses with mobile EEG: A systematic literature review and interactive exploration,” *Psychophysiology*, vol. 62, no. 1, pp. 1–17, 2025, doi: 10.1111/psyp.14743.
- [14] H. M. Merdas, “Elastic Net – MLP – SMOTE (EMS)-Based Model for Enhancing Stroke Prediction,” *Medinformatics*, vol. 1, no. 2, pp. 73–78, 2024, doi: 10.47852/bonviewmedin42022470.
- [15] E. Sutoyo and M. A. Fadlurrahman, “Penerapan SMOTE untuk Mengatasi Imbalance Class dalam Klasifikasi Television Advertisement Performance Rating Menggunakan Artificial Neural Network,” *Jurnal Edukasi dan Penelitian Informatika (JEPIN)*, vol. 6, no. 3, p. 379, 2020, doi: 10.26418/jp.v6i3.42896.
- [16] D. A. Anggoro and D. Permatasari, “Performance Comparison of the Kernels of Support Vector Machine Algorithm for Diabetes Mellitus Classification,” *International Journal of Advanced Computer Science and Applications*, vol. 14, no. 1, pp. 580–585, 2023, doi: 10.14569/IJACSA.2023.0140163.
- [17] D. A. Anggoro and S. S. Mukti, “Performance Comparison of Grid Search and Random Search Methods for Hyperparameter Tuning in Extreme Gradient Boosting Algorithm to Predict Chronic Kidney Failure,” *International Journal of Intelligent Engineering and Systems*, vol. 14, no. 6, pp. 198–207, Dec. 2021, doi: 10.22266/ijies2021.1231.19.
- [18] A. F. B. Sajiwo, B. Rahmat, and A. Junaidi, “Klasifikasi Indeks Standar Pencemaran Udara (Ispu) Menggunakan Algoritma Xgboost Dengan Teknik Imbalanced Data (Smote),” *Jurnal Informatika dan Teknik Elektro Terapan*, vol. 12, no. 3, 2024, doi: 10.23960/jitet.v12i3.4699.
- [19] A. Faisal and A. Subekti, “JEPIN (Jurnal Edukasi dan Penelitian Informatika) Deep Neural Network untuk Prediksi Stroke,” *Jurnal Edukasi dan Penelitian Informatika*, vol. 7, no. 3, p. 443, 2021.
- [20] F. A. H. Airi, T. Suprpti, and A. Bahtiar, “Komparasi Metode Klasifikasi Data Mining Untuk Prediksi Penyakit Stroke,” *E-Link: Jurnal Teknik Elektro dan Informatika*, vol. 18, no. 1, p. 73, 2023, doi: 10.30587/e-link.v18i1.5271.
- [21] H. Albanna, M. R. T. Tamang, C. Patel, and M. S. Sharif, “Revolutionizing heart attack prognosis: Introducing an innovative regression model for prediction,” *Inform Med Unlocked*, p. 101664, Jun. 2025, doi: 10.1016/j.imu.2025.101664.
- [22] Joanna K.M. Ng *et al.*, “Acta Cytologica,” *Karger e-Journal Backfile Collection 2023*, vol. 67, Aug. 2023.
- [23] S. Rizal Sidiq and A. Salam, “SciBERT Optimisation for Named Entity Recognition on NCBI Disease Corpus with Hyperparameter Tuning,” 2025. [Online]. Available: <http://jurnal.polibatam.ac.id/index.php/JAIC>
- [24] C. Herdian, A. Kamila, and I. G. Agung Musa Budidarma, “Studi Kasus Feature Engineering Untuk Data Teks: Perbandingan Label Encoding dan One-Hot Encoding Pada Metode Linear Regresi,” *Technologia : Jurnal Ilmiah*, vol. 15, no. 1, p. 93, 2024, doi: 10.31602/tji.v15i1.13457.
- [25] E. Rajiah, D. Wahyuni, and Hasanuddin, “Prediksi Penyakit Hepatitis C dan Sirosis Hati dengan Penerapan SMOTE pada Metode Jaringan Saraf Tiruan Propagasi Balik,” *PRISMA FISIKA*, vol. 11, no. 3, pp. 71–77, 2023, [Online]. Available: www.kaggle.com.
- [26] A. Widyanto, K. Kusriani, and K. Kusnawi, “Pengaruh Keseimbangan Data terhadap Akurasi Model Support Vector Machine pada Data Set Donor Darah,” *Jurnal Teknologi Terpadu*, vol. 9, no. 2, pp. 79–88, 2023, doi: 10.54914/jtt.v9i2.771.
- [27] H. Permana, Y. Herry Chrisnanto, and H. Ashaury, “Analisis Sentimen Terhadap Bakal Calon Presiden 2024 Dengan Algoritma Multinomial Naïve Bayes Dan Oversampling Smote,” *JATI (Jurnal Mahasiswa Teknik Informatika)*, vol. 7, no. 5, pp. 3257–3264, 2024, doi: 10.36040/jati.v7i5.7309.